Normy macierzowe, uwarunkowanie i rozkład SVD

Rachunek Macierzowy — program 3

Kacper Bujak, Wojciech Maćkowiak

17 kwietnia 2026

1 Cel ćwiczenia

Dla kwadratowej macierzy rzeczywistej M obliczyć normy macierzowe $\|M\|_1$, $\|M\|_2$, $\|M\|_\infty$, normę z klasy norm Schattena dla ustalonego rzędu p (wartości osobliwe z SVD), odpowiadające współczynniki uwarunkowania, pełny rozkład SVD oraz wartości i wektory własne przy użyciu procedur numerycznych Octave (`norm`, `cond`, `svd`, `eig`).

Macierz testowa: losowa $n \times n$ przy $n = 8 + 24 = 32$ (jak w programie 2), ziarno generatora `rng(11)`, odrzucenie macierzy z `rcond`(M) zbyt małym.

2 Opis metody / algorytmu

2.1 Norma $\|M\|_1$ i $\|M\|_\infty$

Norma indukowana z normy wektorowej "suma modułów": $\|M\|_1 = \max_j \sum_i |M_{ij}|$ (największa suma modułów po kolumnach). Norma $\|M\|_\infty = \max_i \sum_j |M_{ij}|$ — po wierszach.

2.2 Norma $\|M\|_2$

$\|M\|_2 = \sigma_{\max}(M)$ — największa wartość osobliwa (spektralna norma operatora liniowego w parze norm euklidesowych na $\mathbb{R}^n$).

2.3 Norma Schattena $\|M\|_{S,p}$ dla ustalonego p

Niech $\sigma_1 \geq \cdots \geq \sigma_n \geq 0$ będą wartościami osobliwymi M. Norma Schattena rzędu p (dla macierzy rzeczywistej): $\|M\|_{S,p} = \left(\sum_i \sigma_i^p\right)^{1/p}$. Dla $p = 2$ pokrywa się z normą Frobeniusa $\|M\|_F$, a nie z $\|M\|_2$; w niniejszym zadaniu przyjęto $p = 4$, by wypełnić punkt "$\|M\|_p$" w sposób jednoznaczny i powiązany z SVD.

2.4 Współczynnik uwarunkowania

Dla norm indukowanych 1, 2, ∞: $\kappa(M) = \|M\|\,\|M^{-1}\|$. Octave zwraca to przez `cond(M,1)`, `cond(M)` (dla 2), `cond(M,inf)`. Dla normy Schattena przyjmujemy analogicznie $\kappa_{S,p} = \|M\|_{S,p}\,\|M^{-1}\|_{S,p}$; wartości osobliwe M^{-1} to $1/\sigma_i$, stąd $\|M^{-1}\|_{S,p} = \left(\sum_i \sigma_i^{-p}\right)^{1/p}$.

2.5 SVD i wartości własne

Rozkład $M = U\Sigma V^{\mathsf{T}}$ z Σ diagonalną nieujemną. Rozkład spektralny (wartości własne, wektory w kolumnach macierzy V) daje `eig(M)` dla macierzy rzeczywistej (wartości własne mogą być zespolone).

3 Implementacja

W katalogu `src/`: skrypt `solution.m` ustala M, wywołuje `norm`, `cond`, `inv` do weryfikacji definicji, `svd`, `eig`, oraz funkcję `schatten_norm_cond.m` liczącą normę Schattena i $\kappa_{S,p}$ z wektora σ. Wyniki liczbowe do tabel zapisuje się do `wyniki_auto.tex`; do wykresów w Pythonie: `singular_values.txt`, `norms_bar.txt`, `cond_samples.txt` (ostatni z proby 250 losowych macierzy $n \times n$ o rozsądnym `rcond`). Skrypt `analysis/plot_template.py` generuje kilka plików PDF w `LaTeX/figures/`.

4 Fragmenty kodu

4.1 Norma Schattena i $\kappa_{S,p}$ z wartości osobliwych

```
function [nrm, kappa] = schatten_norm_cond(s, p)
% Norma Schattena (rzad p na wektorze wartosci osobliwych s) oraz
% wspolczynnik uwarunkowania kappa = ||M||_{S,p} * ||M^{-1}||_{S,p}
% przy pelnym rzedzie (wszystkie s > 0).
  nrm = norm(s(:), p);
  if any(s <= 0)
    kappa = inf;
  else
    kappa = norm(s(:), p) * norm(1 ./ s(:), p);
  endif
endfunction
```

4.2 Główny skrypt: normy, `cond`, przygotowanie danych

```
%% Rachunek Macierzowy - program 3
% Normy macierzowe (1, 2, p, inf), wspolczynniki uwarunkowania, SVD,
    wartosci wlasne (eig).
% Uruchom z katalogu src/:  run('solution.m')

clear all;
clc;

m_ur = 8;
d_ur = 24;
n = m_ur + d_ur;
p_schat = 4;

fprintf('Rachunek Macierzowy, prog. 3: macierz %dx%d, n = miesiac+dzien
    = %d+%d\n', n, n, m_ur, d_ur);

rng(11);
M = rand(n, n);
```

```
rc = rcond(M);
fprintf('rcond(M) = %.3e\n', rc);
if rc < 1e-14
  error('macierz zle uwarunkowana - zmien ziarno RNG');
endif

%% Normy indukowane (subordynowane) 1, 2, inf - Octave norm(M, p)
n1 = norm(M, 1);
n2 = norm(M, 2);
ninf = norm(M, Inf);

%% Wspolczynniki uwarunkowania w normach 1, 2, inf - Octave cond
c1 = cond(M, 1);
c2 = cond(M, 2);
cinf = cond(M, Inf);

%% Porownanie: ||M||*||M^{-1}|| (te same normy)
Minv = inv(M);
c1_def = n1 * norm(Minv, 1);
c2_def = n2 * norm(Minv, 2);
cinf_def = ninf * norm(Minv, Inf);

%% Norma Schattena rzedu p na wartosciach osobliwych (dla punktu ||M||_p
    w poleceniu)
s = svd(M);
[n_schat, k_schat] = schatten_norm_cond(s, p_schat);
```

5 Wyniki numeryczne

5.1 Normy i uwarunkowanie

Tabela 1: Normy macierzy M i współczynniki uwarunkowania (wartości z uruchomienia `solution.m`).

Wielkość	Wartość
$\|M\|_1$	2.061568e+01
$\|M\|_2$	1.645829e+01
$\|M\|_\infty$	2.052300e+01
$\|M\|_{S,4}$ (Schatten)	1.648238e+01
$\mathtt{cond}(M,1)$	2.296702e+03
$\|M\|_1\|M^{-1}\|_1$	2.296702e+03
$\mathtt{cond}(M,2)$	9.052938e+02
$\|M\|_2\|M^{-1}\|_2$	9.052938e+02
$\mathtt{cond}(M,\infty)$	2.205520e+03
$\|M\|_\infty\|M^{-1}\|_\infty$	2.205520e+03
$\kappa_{S,4}$	9.069105e+02

Wiersze z definicją $\|M\|\,\|M^{-1}\|$ pokrywają się z wyjściem `cond` — zgodnie z teorią dla norm indukowanych.

5.2 SVD i spektrum

Tabela 2: Podsumowanie SVD i diagnostyka.

Wielkość	Wartość
$\sigma_{\min}$	1.818006e-02
$\sigma_{\max}$	1.645829e+01
$\|M - U\Sigma V^{\top}\|_F$	5.532555e-14
$\texttt{rcond}(M)$	4.354069e-04
$\|MV_{\text{eig}} - V_{\text{eig}}D\|_F$	3.625770e-14

Małe residuum rozkładu SVD oraz residuum $MV = VD$ potwierdzają poprawność obliczeń bibliotecznych.

5.3 Wykresy

Spektrum wartości osobliwych (rys. 1) pokazuje szybki spadek σ_i: typowe dla losowej macierzy pełnej — energia Frobeniusa koncentruje się na kilku dominujących kierunkach. Rysunek 2 formalizuje to jako skumulowany udział $\sum_{i \le k} \sigma_i^2 / \|M\|_F^2$: często wystarczy niewiele składowych, by przekroczyć np. 90% tej energii.

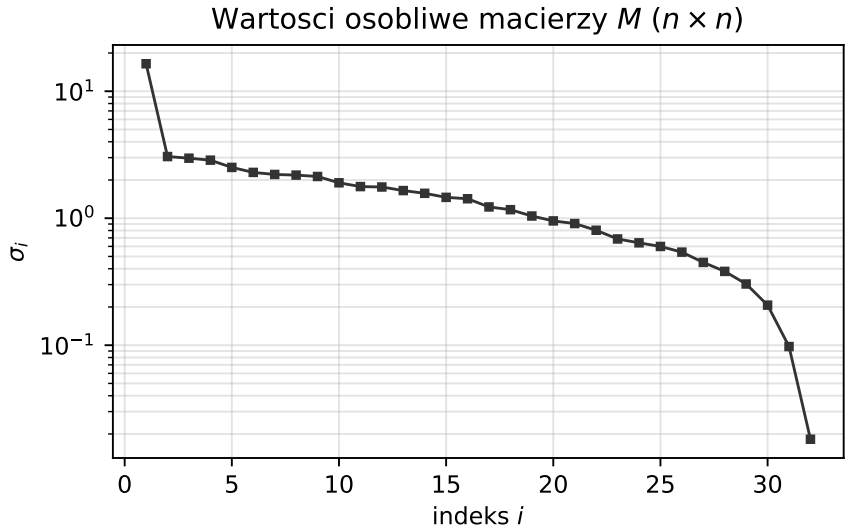

Rysunek 1: Wartości osobliwe σ_i macierzy M (oś y w skali logarytmicznej).

Na rys. 3 widać, że dla tej samej macierzy M normy indukowane 1, 2, ∞ oraz norma Schattena S,4 nie muszą być równe: są to różne sposoby mierzenia "rozmiaru" operatora; nierówności teoretyczne (np. $\|M\|_2 \le \|M\|_F$) można sprawdzić liczbowo na tabeli z sekcji wcześniejszej.

Rysunek 4 przedstawia empiryczny rozkład $\texttt{cond}(A, 2)$ dla wielu losowych A o tym samym n co M. Rozkład jest silnie prawoskośny w skali logarytmicznej: większość macierzy ma umiarkowane uwarunkowanie, a "ogony" odpowiadają rzadkim, trudniejszym numerycznie realizacjom — stąd sens sprawdzania `rcond` przed obliczeniami na odwróconej macierzy.

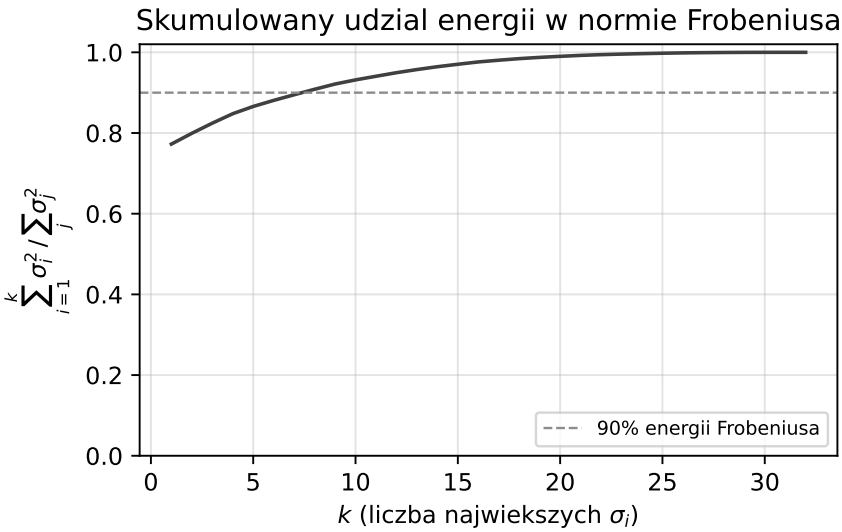

Rysunek 2: Skumulowany udział $\|M\|_F^2$ w największych wartościach osobliwych (rank-k przybliżenie w normie Frobeniusa).

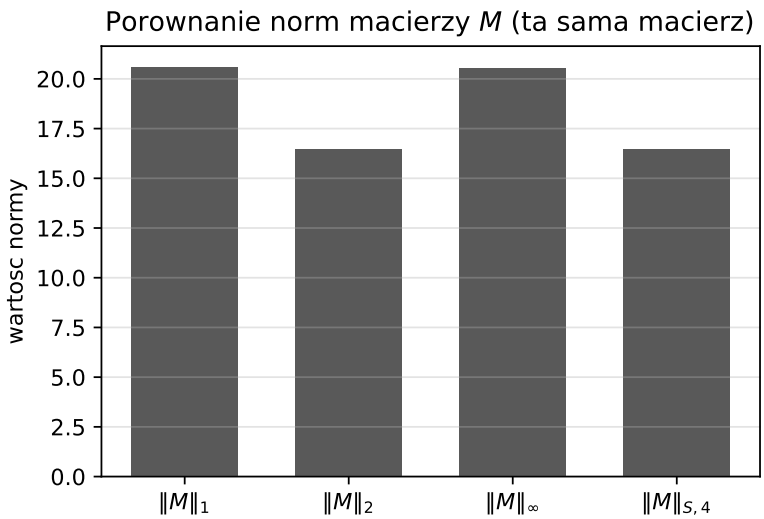

Rysunek 3: Porównanie czterech norm dla jednej macierzy testowej M.

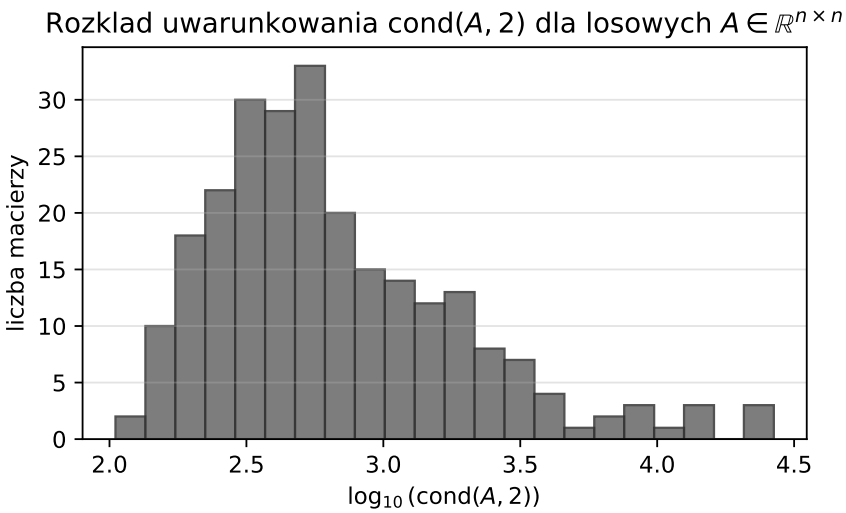

Rysunek 4: Histogram $\log_{10}(\texttt{cond}(A,2))$ dla losowych macierzy $A \in \mathbb{R}^{n\times n}$ ($n = 32$, odfiltrowane osobliwe / złe `rcond`).

6 Wnioski

- **Zgodność definicji.** Wartości `cond` w normach 1, 2 i ∞ pokrywają się z iloczynem $\|M\|\,\|M^{-1}\|$ w tej samej normie, co potwierdza poprawne użycie biblioteki i spójność definicji współczynnika uwarunkowania.

- **Różne normy, różna geometria.** Normy indukowane mierzą maksymalne wzmocnienie wektora w innych normach wektorowych; norma Schattena S,4 zależy od całego spektrum singularnego i dla $p \neq 2$ nie pokrywa się z $\|M\|_2$. W raporcie przyjęto $p = 4$ świadomie, by powiązać punkt "$\|M\|_p$" z SVD i uniknąć niejednoznaczności ogólnej normy indukowanej $\|\cdot\|_p$ dla macierzy.

- **SVD a stabilność.** Bardzo małe residuum $\|M - U\Sigma V^{\mathsf{T}}\|_F$ pokazuje, że numeryczny SVD jest stabilny dla naszej macierzy; stosunek $\sigma_{\max}/\sigma_{\min}$ kontroluje $\texttt{cond}(M,2)$ i wrażliwość na błędy zaokrągleń przy rozwiązywaniu układów z M.

- **Wartości własne vs osobliwe.** Dla macierzy niesymetrycznej moduły wartości własnych nie muszą pokrywać się z σ_i; widoczna zespoloność λ przy rzeczywistym M jest normalna. Małe residuum spektralne $\|MV - VD\|_F$ świadczy o poprawnym zestawieniu par własnych z `eig`.

- **Losowe macierze a typowe uwarunkowanie.** Histogram $\texttt{cond}(A,2)$ sugeruje, że "typowa" losowa macierz ma uwarunkowanie znacznie mniejsze niż pesymistyczne szacunki teoretyczne dla najgorszego przypadku; jednocześnie ogon rozkładu przypomina, że przy wielu losowaniach warto odrzucać patologiczne A (tutaj przez próg na `rcond`).

- **Energia w SVD.** Krzywa skumulowanej energii Frobeniusa wskazuje, że niskorzędowe przybliżenie M może być dokładne w normie Frobeniusa nawet przy małym k — intuicja przydatna przy PCA / kompresji danych i analizie skutecznego wymiaru operatora.