

Rozkład osobliwy macierzy prostokątnej: ścieżka przez AA^T oraz A^TA

Rachunek Macierzowy — program 4

Kacper Bujak, Wojciech Maćkowiak

9 maja 2026

1 Wstęp teoretyczny

1.1 Wartości własne i wartości osobliwe

Wartości własne macierzy kwadratowej M opisują, jak M działa na pewne kierunki (wektory własne): na takim kierunku przekształcenie jest zwykłym skalowaniem przez λ . Wartości osobliwe prostokątnej macierzy $A \in \mathbb{R}^{n \times m}$ opisują natomiast “jak bardzo” mapa liniowa $x \mapsto Ax$ rozciąga przestrzeń wzdłuż swoich głównych osi — po rozwinięciu SVD.

Tabela 1: Porównanie wartości własnych λ i wartości osobliwych σ .

Cecha	Wartości własne (λ)	Wartości osobliwe (σ lub s)
Dla jakich macierzy?	Tylko dla macierzy kwadratowych ($n \times n$).	Dla każdej macierzy (także prostokątnej $n \times m$).
Jakie mogą być?	Mogą być dodatnie, ujemne, zerowe albo zespolone.	Są zawsze rzeczywiste i nieujemne (≥ 0).
Co oznaczają (intuicja)?	Skalowanie wektora w tej samej przestrzeni (np. mapa $\mathbb{R}^2 \rightarrow \mathbb{R}^2$).	Skalowanie “osi” przy przejściu między przestrzeniami (np. $\mathbb{R}^6 \rightarrow \mathbb{R}^4$).
Związek z A	Zależą bezpośrednio od M (tu rozważamy $M = A^TA$ lub $M = AA^T$).	Niezerowe σ_i to pierwiastki z nieujemnych wartości własnych A^TA (i AA^T).

1.2 Macierz osobliwa, macierz ortogonalna

Macierz osobliwa (singular) — w sensie algebraicznym kwadratowa macierz nieodwracalna; równoważnie $\det(M) = 0$. Dla prostokątnej macierzy A mówimy o braku pełnego rzędu: $\text{rank}(A) < \min(n, m)$; wtedy część wartości osobliwych jest zerowa i pojawia się nietrywialne jądro $\ker(A)$. **Macierz ortogonalna** Q spełnia $Q^T Q = I$: zachowuje długości i kąty, więc jest izometrią; kolumny tworzą bazę ortonormalną.

1.3 SVD i rozkład $A = USV^T$

SVD (ang. *Singular Value Decomposition*), czyli rozkład ze względu na wartości osobliwe, pozwala zapisać dowolną macierz $A \in \mathbb{R}^{n \times m}$ jako

$$A = USV^T.$$

Intuicyjnie jest to “rozkład na czynniki” dla macierzy: każde liniowe przekształcenie dane przez A można rozłożyć na trzy proste etapy:

1. obrót (lub symetria ortogonalna) w przestrzeni wejściowej — V^T ;
2. niezależne skalowanie wzdłuż osi — diagonalne S z wartościami nieujemnymi malejąco;
3. obrót w przestrzeni wyjściowej — U .

Macierz S ma rozmiar $n \times m$, jest “diagonalna” w sensie $\Sigma_{ii} = \sigma_i$, a poza przekątnią są zera; niezerowe σ_i są wartościami osobliwymi A . Kolumny U to lewe wektory osobliwe (w $\mathbb{R}^n$), kolumny V — prawe (w $\mathbb{R}^m$).

1.4 Dlaczego $A^T A$ oraz AA^T ?

Gramiany $A^T A$ ($m \times m$) oraz AA^T ($n \times n$) są symetryczne i nieujemnie określone. Niezerowe wartości własne obu macierzy są równe σ_i^2 ; znaków nie ma, więc stabilnie liczy się je przez eig na liczbach rzeczywistych. Ścieżka przez AA^T podaje lewy czynnik U i Σ , po czym odtwarza się V ze wzoru wiążącego obie strony rozkładu; ścieżka przez $A^T A$ najpierw daje V i Σ , a potem U . Koszt operacji eig skali się jak $\mathcal{O}(n^3)$ lub $\mathcal{O}(m^3)$ zależnie od rozmiaru gramianu, więc praktycznie wybiera się mniejszy z wymiarów (tu w ćwiczeniu pokazujemy obie ścieżki dla porównania).

2 Cel ćwiczenia

Po omówieniu pojęć z sekcji 1 rozwiązujemy konkretne zadanie numeryczne: przejść krok po kroku przez konstrukcję rozkładu osobliwego (SVD) macierzy prostokątnej $A \in \mathbb{R}^{n \times m}$ na dwa sposoby — z macierzy AA^T (wektory lewe U i wartości osobliwe) oraz z $A^T A$ (wektory prawe V), porównać wyniki z procedurą `svd` z Octave oraz wyznaczyć wymiary obrazu i jądra operatora $x \mapsto Ax$ przy interpretacji $A : \mathbb{R}^m \rightarrow \mathbb{R}^n$.

3 Opis metody / algorytmu

3.1 Ścieżka przez AA^T

Macierz AA^T jest symetryczna i nieujemnie określona, ma więc rzeczywiste wartości własne $\lambda_i \geq 0$ oraz ortonormalną bazę wektorów własnych w kolumnach U . Przyjmujemy $\sigma_i = \sqrt{\lambda_i}$ (malejąco) i diagonalne Σ . Wtedy $V = A^T U \Sigma^+$, gdzie Σ^+ to pseudoodwrotność Moorea–Penrose’ego macierzy diagonalnej (odwrotność na dodatnich σ_i , zero gdy $\sigma_i \approx 0$). Rekonstrukcja ma postać $A \approx U \Sigma V^T$.

3.2 Ścieżka przez $A^T A$

Analogicznie z $A^T A$ otrzymujemy V oraz Σ , a następnie $U = AV\Sigma^+$. W obu przypadkach zestaw dodatnich σ_i (rzęd r) powinien zgadzać się z wartościami osobliwymi zwróconymi przez `svd`.

3.3 Obraz i jądro

$\dim R(A) = \text{rank}(A) = r$, natomiast $\dim N(A) = m - r$ dla $A : \mathbb{R}^m \rightarrow \mathbb{R}^n$.

4 Implementacja

Skrypt `../src/solution.m` generuje macierz testową A o rozmiarze 4×6 , zapisuje dziennik `octave_out.txt`, makra `wyniki_auto.tex`, tabele liczb `matrix_tables_auto.tex` oraz pliki `prog4_*.txt` (surowe macierze dla ewentualnych narzędzi pomocniczych) w katalogu LaTeX/. Skrypt `benchmark_svd.m` uruchamiany po rozwiązaniu zapisuje `benchmark_auto.tex` z pomiarem czasu. Program python `analysis/plot_prog4.py` (z katalogu głównego zadania) buduje heatmapy PDF w LaTeX/figures/ na podstawie `prog4_*.txt`.

5 Fragmenty kodu

Pełny skrypt `solution.m` (inicjalizacja, zapis `dlmwrite`, `diary`, eksport pod wykresy) nie jest wklejany do sprawozdania — poniżej tylko fragmenty odpowiadające dwóm ścieżkom SVD oraz porównaniu z `svd`.

5.1 Ścieżka AA^T : wartości osobliwe i V

Rozkład spektralny $AA^T = U \text{diag}(\lambda) U^T$ w Octave daje `eig`; sortujemy malejąco λ , $\sigma_i = \sqrt{\max(0, \lambda_i)}$, budujemy diagonalną Σ^+ (zerując odwrotność przy σ_i poniżej progu). Następnie $V = A^T U \Sigma^+$ (wymiały $m \times n$ przy pełnym U).

```

1 [U_e, D_e] = eig(AAT);
2 lam_AAT = real(diag(D_e));
3 [lam_AAT, ord] = sort(lam_AAT, 'descend');
4 U1 = real(U_e(:, ord));
5 sigma1 = sqrt(max(0, lam_AAT));
6 Sigma1 = diag(sigma1);
7 tol = max(n, m) * eps * max([max(sigma1); 1e-16]);
8 inv_sigma1 = zeros(n, 1);
9 for i = 1:n
10     if sigma1(i) > tol
11         inv_sigma1(i) = 1 / sigma1(i);
12     endif
13 endfor
14 Sigma1_pinv = diag(inv_sigma1);

```

```

1 %% --- 5-6) V = A' * U * Sigma^+ (pseudoodwrotnosc diagonalna) ---
2 V1 = A' * U1 * Sigma1_pinv;
3 fprintf('\n--- 5-6) V z wlasnosci V = A^T U Sigma^+ (wymiały %d x %d)\n', rows(V1),
4     columns(V1));
5 fprintf('V jako macierz (kolumny V_i); wierszami (V_i') do porownania z poleceniem:\n');
6 disp(V1');
7 recon1 = U1 * Sigma1 * V1';
8 res1 = norm(A - recon1, 'fro');

```

```
9 fprintf('||A - U Sigma V^T||_F (sciezka AA') = %.3e\n', res1);
```

5.2 Ścieżka $A^T A$ oraz U

Analogicznie z $A^T A$ otrzymujemy V i Σ , potem $U = AV\Sigma^+$ (tu U ma rozmiar $n \times m$).

```
1 [V_e, D_v] = eig(ATA);
2 lam_ATA = real(diag(D_v));
3 [lam_ATA, ord2] = sort(lam_ATA, 'descend');
4 V2 = real(V_e(:, ord2));
5 sigma2 = sqrt(max(0, lam_ATA));
6 Sigma2 = diag(sigma2);
7 inv_sigma2 = zeros(m, 1);
8 for i = 1:m
9     if sigma2(i) > tol
10         inv_sigma2(i) = 1 / sigma2(i);
11     endif
12 endfor
13 Sigma2_pinv = diag(inv_sigma2);
```

```
1 %% --- 10-11) U = A V Sigma^+ ---
2 U2 = A * V2 * Sigma2_pinv;
3 fprintf('\n--- 10-11) U z U = A V Sigma^+ (wymiarzy %d x %d)\n', rows(U2), columns(U2));
4 disp(U2);
5
6 recon2 = U2 * Sigma2 * V2';
7 res2 = norm(A - recon2, 'fro');
8 fprintf('||A - U Sigma V^T||_F (sciezka A''A) = %.3e\n', res2);
```

5.3 Odniesienie: svd

```
1 %% --- 12) Porównanie z svd(A) ---
2 [Us, Ss, Vs] = svd(A);
3 recon_svd = Us * Ss * Vs';
4 res_svd = norm(A - recon_svd, 'fro');
5 s_svd = diag(Ss);
6 s_svd = s_svd(1:min(n, m));
```

6 Wyniki numeryczne

6.1 Podsumowanie liczbowe

6.2 Interpretacja wyników z tabeli podsumowującej

Normy $\|A - U\Sigma V^T\|_F$ mierzą błąd rekonstrukcji macierzy z rozkładu SVD uzyskanego daną ścieżką. Wartości rzędu 10^{-15} przy arytmetyce double oznaczają zgodność z dokładnym rozkładem z dokładnością do błędów zaokrągleń — nie ma tu istotnego residuum: Σ^+ zeruje wartości poniżej progu numerycznego, a iloczyn $U\Sigma V^T$ odtwarza A . Wiersze $\max |\sigma_i - \sigma_{i,\text{svd}}|$ pokazują, że niezerowe wartości osobliwe z obu gramianów pokrywają się z bibliotecznym $\text{svd}(A)$ co do precyzji maszynowej (często 10^{-15} – 10^{-16}). $\dim R(A) = \text{rank}(A)$ to liczba niezerowych wartości osobliwych (przy rozróżnieniu numerycznym); $\dim N(A) = m - r$ wynika ze wzoru rangi–nullości dla $A: \mathbb{R}^m \rightarrow \mathbb{R}^n$: wektory z $\ker(A)$ są dopełnieniem ortogonalnym obrazu A^T w przestrzeni startowej.

Tabela 2: Parametry testu i jakość rekonstrukcji (wartości z `wyniki_auto.tex`).

Wielkość	Wartość
n, m	4, 6
$\text{rank}(A)$	4
$\ A - U\Sigma V^T\ _F$ dla ścieżki AA^T	$2.532471e - 15$
$\ A - U\Sigma V^T\ _F$ dla ścieżki $A^T A$	$2.830342e - 15$
$\ A - U\Sigma V^T\ _F$ (svd)	$3.174615e - 15$
$\max \sigma_i - \sigma_{i,\text{svd}} $, ścieżka AA^T	$1.110223e - 15$
$\max \sigma_i - \sigma_{i,\text{svd}} $, ścieżka $A^T A$	$4.440892e - 16$
$\dim R(A)$	4
$\dim N(A)$	2

6.3 Tabele macierzy (wartości liczbowe)

Bezpośrednio wpisy macierzy z tego samego przebiegu Octave.

Tabela 3: Macierz testowa A (4×6)

0.48063	-0.27267	0.01397	0.35692	-1.26570	0.52776
-0.51606	2.49880	0.38784	-0.03097	-0.77507	0.05679
0.40121	-0.56413	-0.91881	-0.12190	-0.81296	-0.50244
-1.68402	-1.27201	-0.71118	-0.71257	0.41304	0.42344

Tabela 4: AA^T (4×4)

2.31346	0.07595	1.05409	-1.02611
0.07595	7.26566	-1.36771	-2.85930
1.05409	-1.36771	2.25163	0.23371
-1.02611	-2.85930	0.23371	5.81738

6.4 Heatmapy tych samych macierzy

Te same dane co powyżej — wizualizacja kolorowa (`imshow`); oś j to kolumny, i to wiersze (indeksy od 1).

6.5 Benchmark czasu obliczeń

Porównanie średniego czasu pięciu przebiegów dla losowych macierzy $\mathcal{N}(0,1)$ tego samego rozmiaru. Skrypty `.m` są wykonywane przez interpreter Octave; wywołanie `svd(A)` ko-

Tabela 5: $A^T A$ (6×6)

3.49422	0.49518	0.63558	1.33859	-1.23008	-0.69031
0.49518	8.25462	2.38828	0.80046	-1.65840	-0.25717
0.63558	2.38828	1.50060	0.61174	0.13492	0.18991
1.33859	0.80046	0.61174	0.65096	-0.62297	-0.05387
-1.23008	-1.65840	0.13492	-0.62297	3.03422	-0.12864
-0.69031	-0.25717	0.18991	-0.05387	-0.12864	0.71351

Tabela 6: V^T ze ścieżki AA^T

-0.18531	-0.89301	-0.27915	-0.14308	0.26238	0.03090
0.79218	-0.31873	-0.05735	0.27254	-0.42405	-0.11607
-0.37706	0.00554	-0.41859	-0.15088	-0.79480	0.16762
0.09103	0.20527	-0.54531	-0.25240	0.13406	-0.75534




Tabela 7: V^T ze ścieżki $A^T A$


-0.18531	-0.89301	-0.27915	-0.14308	0.26238	0.03090
-0.79218	0.31873	0.05735	-0.27254	0.42405	0.11607
0.37706	-0.00554	0.41859	0.15088	0.79480	-0.16762
0.09103	0.20527	-0.54531	-0.25240	0.13406	-0.75534
-0.15551	0.10953	-0.47770	0.82798	0.19287	0.11346
-0.40431	-0.21629	0.46691	0.36501	-0.25388	-0.61161

Tabela 8: U ze ścieżki $A^T A$ (4×6)

-0.06935	-0.49176	-0.54520	-0.67537	-0.00000	0.00000
-0.78270	0.43229	-0.43277	0.11497	-0.00000	-0.00000
0.15214	-0.43526	-0.51865	0.72000	-0.00000	-0.00000
0.59952	0.61794	-0.49645	-0.11074	0.00000	-0.00000

Macierz testowa A (4x6)

Rysunek 1: Macierz testowa A (4×6): $|A_{ij}|$ oraz A_{ij} z mapą dwubiegunową.Rysunek 2: Macierze AA^T oraz $A^T A$.Rysunek 3: V^T z obu ścieżek (wiersze — odpowiedniki zapisu wierszami w `solution.m`).



Rysunek 4: Macierz U ze ścieżki $A^T A$ (wymiar $n \times m$).

rzysta z zoptymalizowanej biblioteki numerycznej (LAPACK), czyli kodu skompilowanego na poziomie biblioteki — sensowny punkt odniesienia dla czasu.

Tabela 9: Średni czas pojedynczego przebiegu (pieć powtórzeń; losowa macierz $\mathcal{N}(0,1)$ na rozmiarze $n \times m$). Ścieżki jak w `solution.m`; `svd(A)` wywołuje bibliotekę numeryczną (LAPACK).

Rozmiar	AA^T [ms]	$A^T A$ [ms]	<code>svd(A)</code> [ms]
4×6	3.395	0.537	0.119
40×60	2.839	3.167	1.988
400×600	400.538	774.063	974.696

7 Wnioski

Teoria z sekcji 1 oraz wyniki liczbowe potwierdzają, że obie ścieżki (AA^T oraz $A^T A$) prowadzą do tego samego zestawu wartości osobliwych co `svd`, a rekonstrukcja $U\Sigma V^T$ ma residuum rzędu błędu zaokrągleń zmiennoprzecinkowych — tak jak dla bibliotecznego SVD. Niezerowe σ_i są pierwiastkami z nieujemnych wartości własnych obu gramianów, a wzory na brakujący czynnik (V albo U) odtwarzają związek między lewymi a prawymi wektorami osobliwymi.

Tabela benchmarku (tab. 9). Dla rozmiaru 400×600 mamy $n < m$, więc macierz AA^T jest mniejsza (400×400) niż $A^T A$ (600×600) — ścieżka przez AA^T jest wtedy tańsza niż przez $A^T A$, co widać po krótszym czasie eig na mniejszej macierzy. Natomiast wbudowane `svd(A)` jest zwykle najszybsze dla dużych rozmiarów: korzysta z podprogramów LAPACK dopasowanych do struktury zadania i nie powtarza jawnych pełnych macierzy pomocniczych tak jak nasza demonstracyjna implementacja. Dla małych macierzy (4×6) różnice są rzędu pojedynczych milisekund i zależą od narzutu interpretera i cache procesora.

W praktyce numerycznej istotny jest wybór progu dla Σ^+ : zbyt mała tolerancja pozostawia “sztuczne” małe σ z błędów rozkładu własnego AA^T przy $n > m$ (nadmiarowe zera spektralne), zbyt duża — obcina prawdziwy rząd. W skrypcie użyliśmy progu typu

$\max(n, m) * \text{eps} * \max(\text{sigma})$ (skala względna względem największej wartości osobliwej), a do interpretacji geometrycznej $\dim R(A)$ i $\dim N(A)$ bezpieczniej jest oprzeć się na $\text{rank}(A)$.

Ścieżka przez AA^T jest kosztowniejsza, gdy $n \gg m$ (macierz $n \times n$), a przez $A^T A$ — gdy $m \gg n$. W obu wariantach stabilność zależy od separacji wartości osobliwych i od tego, czy używamy pełnego czy ekonomicznego SVD; tutaj pokazano wariant pełny (np. U z pierwszej ścieżki jest $n \times n$), co ułatwia porównanie z definicją z wykładu, ale w aplikacjach częściej stosuje się `svd(A, 'econ')`.

Podsumowując: ćwiczenie ilustruje równoważność algebraicznych konstrukcji SVD; różnią się one kosztem i szczegółami implementacji, nie zaś wynikiem przy poprawnym sortowaniu λ i pseudoinwersji zerowych σ .